

딥러닝을 이용한 가로경관과 범죄 발생과의 상관관계 분석

1. 1. 1. 1. 1. 2*

Correlation Analysis between Street Landscape and Crime Occurrence
Using Deep LearningSeoyeong Kim¹ · Hayeon Noh¹ · Yewon Yoon¹ · Haemin Lee¹ · Jinwoong Jung¹ · Hayoung Oh^{2*}¹Undergraduate Student, Applied Artificial Intelligence, Sungkyunkwan University, Seoul, 03063 Korea^{2*}Associate Professor, College of Computing and Informatics, Sungkyunkwan University, Seoul, 03063 Korea

요 약

본 연구는 시카고에서 365일 동안 발생한 범죄 발생 위치에 대응하는 이미지 데이터셋에 전이학습된 VGG16을 적용하여 가로경관과 범죄 발생과의 상관관계를 파악하는 모델을 제안한다. 범죄 발생 및 미발생 지역의 위치 좌표와 Google Maps Static API를 활용하여 구글 스트리트뷰의 가로경관 이미지로 구축한 데이터셋을 바탕으로, 기존의 VGG16 모델을 전이학습시킨 후 해당 모델의 정확도와 손실 정도를 구하고 가로경관과 범죄 발생 사이에 유의미한 상관관계가 있는지 파악하고자 한다. 두 개의 서로 다른 서브 데이터셋에 대하여 유사한 정도의 검증 정확도와 평가 정확도가 유의미하게 도출되었다. 이는 데이터가 일관된 특징을 내포함을 입증하는 한편, 가로경관과 범죄 발생 간의 상관관계가 존재함을 시사한다.

본 연구는 기존의 연구와는 달리 설문조사 등으로 수집한 주관적 지표가 아닌 객관적인 실제 범죄 지표를 사용하여 상관관계를 파악한다. 또한, 기존의 연구가 잠재적 피해자의 입장에서 행해진 것과 달리, 범죄 주체 입장에서 범죄 발생 요인을 파악하는 관점을 취함으로써 기존 연구들이 피해자에게 부여하였던 책임 소재를 올바른 위치인 가해자에게 돌려놓음과 동시에 가로경관과 범죄율 사이의 상관관계에 있어 보다 강한 근거를 제시한다. 이는 이미지 기반 딥러닝 모델의 활용이 우범 예상 지역의 치안 강화 등의 범죄 예방 행위에 긍정적인 영향을 미칠 수 있으며, 추후 범죄 발생에 영향을 미치는 가로경관의 요인을 보다 정밀하게 파악하는 것이 범죄 예방에 실질적인 도움 가능성으로 이어질 수 있음을 역설한다.

ABSTRACT

In this study, we propose a model for identifying the correlation between streetscape and crime by applying transfer-trained VGG16 to the image dataset corresponding to the location of the crime occurring for 365 days in Chicago. Based on the data set built with the streetscape image of Google Street View using the location coordinates of the crime-occurring and non-criminal areas and the Google Maps Static API, we tried transfer learning of the existing VGG16 model and then the accuracy and degree of loss of the model. The purpose of this study is to determine whether there is a significant correlation between streetscape and crime occurrence. For two different sub-datasets, similar levels of verification accuracy and evaluation accuracy were significantly derived. While this demonstrates that the data contain consistent features, it suggests that a correlation exists between streetscape and crime incidence.

키워드 : 딥러닝, VGG16 모델, 범죄, 가로경관

Keywords : Deep learning, VGG16 model, crime, street landscape

Received 1 August 2022, Revised 19 October 2022, Accepted 3 January 2023

* Corresponding Author Hayoung Oh(E-mail:hyoh79@gmail.com, Tel:+82-02-740-1774)

Associate Professor, College of Computing and Informatics, Sungkyunkwan University, Seoul, 03063 Korea

Open Access <http://doi.org/10.6109/jkiice.2023.27.2.152>

print ISSN: 2234-4772 online ISSN: 2288-4165

© This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.
Copyright © The Korea Institute of Information and Communication Engineering.

I. 서 론

1.1 선행연구

범죄의 발생에는 다양한 시공간적 요소들이 영향을 미친다. Topinard(1870)에 의해 처음 사용된 ‘범죄학(Criminology)’은 통계적, 심리적 관점에서 이러한 요소를 분석한다.[1]

19세기 후반 미국의 도시들은 인구집중으로 인한 범죄율 증가 등 여러 도시문제를 겪고 있었다. 이러한 문제를 해결하기 위해 19세기 말부터 20세기 초 미국에서는 도시의 질서와 체계를 정비하기 위한 ‘도시 미화 운동(City Beautiful Movement)’이 진행되었다.[2] 이러한 동향에 따라 도시의 환경을 개선하기 위한 많은 후속 연구가 이루어졌는데, 그중 Jacobs(1961)는 도시 환경을 설계할 때 자연적 감시를 통한 범죄 예방 효과를 고려한다고 강조하였다.[3] 비슷한 맥락으로 Jeffery(1971)는 도시의 물리적 환경을 개선하면 범죄 발생 위험과 범죄로 인한 심리적 불안감을 줄일 수 있음을 파악하고, 도시환경설계(CPTED)의 중요성을 강조하였다[4]. 또한, Newman(1972)은 ‘방어적 공간 이론’을 통해 범죄로부터 방어적인 공간을 만들기 위한 요소로 공간의 영역성, 자연적 감시, 지역의 이미지가 있는 장소, 안전한 지역의 접근성 등을 필요로 한다고 주장하였다[5]. 이에 따라, 국내외에서는 범죄와 도시 환경 사이의 상관성을 파악하기 위한 다양한 연구들이 진행되었다.

노지현(2017)은 주거지역의 가로형태에서 범죄에 대한 불안감에 영향을 미치는 다양한 요인들 간의 상관관계를 분석하였다[6]. 연구 대상지별 가로경관 조사 후 여러 요소들과 계층별로 주는 불안감의 정도 및 그 특징들 간에 상관관계가 있음을 도출하였다. 신민규(2018)는 5대 범죄(살인, 강도, 강간, 절도, 폭력)와 주변의 물리적 환경 요인들 사이의 상관분석을 진행하였다. 5대 범죄의 각 건수를 종속 변수로, 도로폭이나 시선사각지대 등의 물리 환경적 요소들을 독립변수로 두어 회귀분석을 진행하여 범죄 종류에 따른 각 속성별 상관성 계수들을 도출하였다. 이를 통하여 좁은 도로폭과 가건물은 살인 및 폭력 범죄 발생에, 가건물과 비포장도로는 절도 범죄 발생에 영향을 미친다는 사실을 밝혔다[7]. 김창규(2014)는 부산광역시 금정구 일대의 범죄 자료들을 바탕으로 하여 5대 범죄 유형별 발생 빈도수와 공간적 특성에 대하여 연구하였다. 연도, 시간대, 요일 등의 시간적 요소와

행정동 등의 공간적 특성을 고려하여 SPSS를 이용한 상관관계분석 및 회귀분석을 진행함으로써 범죄 발생의 분포 패턴을 좁은 오차범위 내로 파악할 수 있었다.[8]

이기인(2017)은 실험 참가자들에게 Google Street View(GSV) 영상을 임의로 보여준 후 ‘안전하다’, ‘안전하지 않다’, ‘동등하다’ 중 하나를 선택하게 함으로써 안전도에 대한 주관적 데이터를 수집하였다. 이 실험을 통해, 공사 중인 장소, 지지부진한 거리 영상이 주로 안전하지 않은 공간으로 인식되고, 가로수가 많거나 깔끔한 거리가 안전한 공간으로 인식됨을 파악했다[9]. 다만 이 연구는 데이터 자체의 주관성으로 인하여 연구의 객관성이 다소 부족하다는 한계점이 있다. 또한, 범죄의 주체가 아닌 잠재적 피해자 입장에서 진행된 실험이므로 결과가 범죄 발생과 유의미한 상관관계를 가진다는 주장에 대한 설득력이 부족하다.

박진아(2020)는 시지각-인지를 바탕으로 인공지능을 활용한 딥러닝 경관 평가 모델을 개발하였다. 이 연구는 아이트래킹 기법을 활용하여 근린경관 평가에 영향을 미친 시지각-인지 요소를 파악했다는 것에서 의의가 있다. 또한, 설문조사를 통해 파악한 도시 경관에 대한 6가지 감정 요소를 담은 Place Pulse 2.0 Dataset을 바탕으로 사람들이 느끼는 범죄 위험도에 따른 딥러닝 경관 평가 모델을 개발하였다[10]. 박근덕(2021)은 서울시 보행만족도 조사 지점의 GSV 이미지를 추출한 후, 성별, 나이와 시각적 복잡도, 천공개폐율, 색상복잡도 등 여러 변수를 설정하였다. 이들을 모두 고려한 의미론적 분할기법을 통하여 회귀분석을 진행하였다. 이 연구는 가로경관의 요소를 하늘까지 확장하였다는 점에서 의미가 있다.[11]

II. 분석 알고리즘

2.1 데이터 전처리

데이터셋의 특성상 범죄 발생 지역의 위치 데이터와 범죄 미발생 지역의 위치 데이터 사이의 비율이 균일하지 않다. 이렇듯 데이터 사이의 비율이 불균형한 경우 학습한 모델의 성능이 낮을 수 있다. 이를 해결하기 위하여 이미지 데이터 증강 과정을 거쳐 학습 데이터의 양을 늘릴 필요가 있다. ImageDataGenerator 클래스는 Keras에서 제공하는 패키지로, 데이터의 증식을 위하여 색상 및 밝기 변화, 각도 회전, 상하 및 좌우로의 이동,

뒤집기 등의 조정을 통해 기존의 데이터로부터 파생되는 새로운 데이터들을 만들어낸다.

2.2 딥러닝 모델

2.2.1 합성곱층 (Convolution layer)

합성곱층은 이미지를 분류하는 데 필요한 특징 정보들을 뽑아내는 역할을 하며, 필터와 ReLu 활성화 함수로 구성된다. 필터를 통과한 이미지의 픽셀값은 합성곱 연산을 통해 변환된다. 이 과정에서 이미지들의 색상, 선, 형태, 경계 등의 특징이 뚜렷해진다. ReLu 활성화 함수는 layer에 비선형성을 증가시켜주는 역할을 한다. 입력값이 음수이면 0으로 비활성화시키고, 양수면 그대로 출력한다.

2.2.2 풀링층(Pooling layer)

풀링층(Pooling layer)는 이미지 데이터들의 공간을 축소해주는 역할을 한다. 풀링층에서는 학습이 진행되지 않아 파라미터의 수가 줄어들어 과적합을 방지할 수 있다. 풀링에는 필터가 적용되는 영역에서 픽셀의 최대값을 구해 사용하는 Max Pooling과 픽셀의 평균값을 구해 사용하는 Average Pooling이 있다.

2.2.3 완전 연결 계층(Fully connected layer)

Fully connected layer는 1차원 배열의 형태로 된 행렬을 통해 이미지를 분류하는 데 사용되는 계층이다. 우선 이미지의 2차원 벡터 행렬을 1차원의 배열로 평탄화시킨다. 이후 ReLu 활성화 함수로 뉴런을 활성화시킨다. 마지막으로 Softmax 함수로 이미지를 최종 분류해 준다. Softmax 함수는 소프트맥스 회귀에 사용되는 함수로, 최대값을 확장하여 다른 요소들과의 차이를 증폭시켜준 뒤 가장 확률이 높은 요소를 결과로 출력한다.

2.2.4 패딩(Padding)

패딩(Padding)은 이미지의 테두리에 일정한 값을 넣어주는 작업으로, 보통 0의 값이 사용되며 이를 제로 패딩(Zero Padding)이라고 한다. 패딩에는 Valid Padding과 Same Padding이 있다. Valid Padding은 padding을 하지 않는 것을 의미하며, Same Padding은 출력 이미지의 크기가 입력 이미지의 크기와 같게 하는 것을 의미한다. 합성곱 연산을 할 때마다 이미지의 크기가 축소되면 깊게 학습시키는 데 문제가 발생할 수 있는데, Same

Padding 작업을 하면 연산 결과 실제 입력된 이미지와 같은 크기의 결과가 출력되어 이를 방지할 수 있다.

2.2.5 스트라이드(Stride)

스트라이드(Stride)는 이미지에 필터를 적용하는 위치의 간격을 의미한다. Stride가 커지면 출력 크기는 작아지게 된다.

2.2.6 드롭 아웃(Drop-out)

Drop-out은 과적합을 줄이기 위한 정규화 방법이다. 신경망 층에 있는 여러 노드들 중 무작위로 몇몇 노드들을 제외하는 방식으로 진행된다.

2.3 VGG16

VGG16은 VGGNet의 일종으로, 16개의 층으로 구성되어 있다. VGG16은 합성곱 필터의 사이즈가 3*3으로 고정되어 있으며, 스트라이드는 1로 설정되어 있다. 따라서 공간적 padding이 발생하더라도 공간적 화질이 보존된다. VGG16은 13개의 합성곱층과 3개의 완전 연결 계층으로 구성되어 있다. 완전 연결 계층은 각각 4096, 4096, 1000개의 유닛으로 구성되어 있다. 다른 모델들과 VGG 모델의 가장 큰 차이점은 3x3 크기의 작은 필터를 사용한다는 점이다. 7x7 필터를 이용해 한 번 합성곱한 것과 비교했을 때 3x3 필터로 세 번 합성곱하게 되면 결정 함수의 비선형성이 증가하고, 학습 파라미터의 수가 감소하게 되어 이미지 분류의 정확도가 높아진다.

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Fig. 1 VGG16 model

2.4 전이학습

전이학습이란 다른 과업에서 학습한 내용을 현재 목표로 하는 과업에 적용할 수 있는 능력을 가지게 하는 것을 말한다. 전이학습 모델은 사전 학습된 모델의 특정 계층에 새로운 계층을 덧붙이는 방식으로 구축한다. 학습 시에는 사전 학습된 모델의 마지막 계층을 제외한 모든 신경망을 고정(freezing)하여 가중치를 유지하고, 새롭게 추가된 계층들에 한정하여 실제 적용하고자 하는 분야의 데이터를 학습 후 가중치를 갱신한다.

2.5 파인튜닝 (Fine Tuning)

VGG16 모델을 전이학습 시켰으나 여전히 낮은 정확도를 보일 때 파인 튜닝을 통해 CNN의 일부 계층만 세밀하게 학습시킨다.

III. 연구 방법

본 연구는 시카고의 범죄 발생 지역에 대한 이미지 데이터가 전이학습된 VGG16을 이용하여 범죄와 가로경관 간의 상관관계를 파악한 후, 이미지를 입력했을 때 실제 범죄 발생 가능성을 예측하는 모델을 구축하는 것을 목표로 한다. 구현 환경은 구글의 코랩 프로 플러스(Colab pro plus)이고, 케라스 텐서플로우(Keras tensorflow) 라이브러리를 활용한다. 사용 언어는 파이썬(Python)이다.

3.1 Raw Data

본 연구의 연구 대상은 시카고의 범죄 발생 지역에 대한 csv 데이터셋이다. 기간은 2021년 4월 20일부터 2022년 4월 19일까지 365일 동안 발생한 범죄로 제한한다. 본 데이터셋은 210,285건의 범죄 데이터로 구성되어 있으며, 범죄 발생 번호(case#), 날짜(date of occurrence), 범죄 종류(primary description), 범죄의 정도(secondary description), 범죄 발생지 유형(location description), 체포 여부(arrest), 가정 폭력 여부(domestic), 그리고 범죄 발생지의 위도(latitude), 경도(longitude), 위치(location) 등을 특성으로 가진다. 범죄의 종류는 'theft', 'battery', 'criminal damage' 등 31개로 구분되고, 범죄 발생지 유형은 'street', 'apartment', 'residence' 등 128개로 구분된다.

본 연구에서는 범죄 발생 지역의 GSV 이미지 데이터 수집을 위해 데이터를 가공하여 사용하였다. 먼저, 범죄의 종류나 범죄 발생지 유형 항목의 데이터에서 결

측값이 존재하는 경우를 제외한 205,901건의 데이터만을 사용하였다. 본 연구의 목적인 범죄와 가로경관 사이의 상관관계 분석을 위해 범죄 발생 지역을 야외이면서 가로경관의 파악에 용이한 'street', 'sidewalk', 'alley'로 한정하여 데이터셋을 구성하였다. 범죄 발생 지역 외에 기타 요소들은 구분하지 않았다. 이 조건을 만족하는 69,298건의 데이터를 추출하였다.

범죄 발생 지역과 미발생 지역을 비교하기 위해 대조군 데이터로 범죄 미발생 지역의 좌표 데이터를 임의로 생성하였다. 먼저, 시카고 지역의 위치 좌표를 랜덤으로 추출하였다. 이때 위도 및 경도 좌표값 중 0.0002 이내의 차이를 갖는 다른 좌표값은 스트리트뷰 이미지 상에서 변별할 수 없었다. 따라서 해당 좌표와 다른 좌표의 위도와 경도 모두 0.0002 이내의 차이가 나타나는 경우, 해당 좌표를 제외하였다. 또한 해당 좌표와 범죄 발생 지역의 좌표의 위도와 경도 모두 0.0002 이내의 차이가 나타나는 경우, 마찬가지로 해당 위치의 좌표를 제외하고 30,000건의 데이터를 추출하였다.

3.2 데이터 전처리

3.2.1 데이터 크롤링

상기의 데이터셋에서 위도와 경도 항목만을 추출한 후, Google Maps Static API를 활용하여 GSV에서 제공하는 해당 좌표의 이미지를 다운로드하였다. 범죄에 영향을 미치는 주변의 가로경관을 모두 고려하기 위해 한 좌표당 좌측면(270°), 정면(0°), 우측면(90°), 후면(180°) 총 4장의 이미지를 다운로드하였으며, 한 이미지의 시야각(fov)은 90°로 설정하였다. API의 요청 오류로 다운로드에 실패한 좌표들을 제외하고 범죄 발생 지역의 이미지 데이터 55,523개, 범죄 미발생 지역의 이미지 데이터 29,146개로 데이터셋을 구성하였다. 이후, 같은 좌표의 4장의 사진을 하나로 병합하는 과정을 거쳤으며, 최종 이미지 파일의 크기는 640*640로 재구성하였다.



Fig. 2 Image Example

3.2.2 데이터 증강 및 차원 축소

범죄 발생 지역과 범죄 미발생 지역의 데이터 개수 차이의 불균형과 적은 수의 데이터로 인해 과적합이 발생할 가능성을 고려하여 ImageDataGenerator을 사용하여 데이터 증강 과정을 거쳤다. 회전 가능 범위는 180도 이내로, 이동 가능 범위는 사진의 20%로, 좌우 및 상하 반전이 가능하도록 설정하였다. 또한, VGG16 모델에 필요한 이미지 형식에 맞추기 위해 이미지 차원을 조정하였다. 이미지 파일의 크기는 224*224로 설정하고, 색상은 R, G, B 3개의 채널로 표현하였다. 이후, VGG16 모델에 사용되는 이미지 형식에 맞추어 0~255 사이의 값으로 정규화 후 RGB 채널을 B-R-G 순으로 재정렬하였다.

3.3 최종 데이터셋 구축

데이터는 범죄 발생 지역과 범죄 미발생 지역으로 이진분류하여 라벨링하였다. 전체 데이터를 학습(train): 테스트(test): 검증(validation) = 64:16:20의 비율로 나누었다. 그 결과 범죄 발생 지역(Crime)은 학습 데이터 35,534개, 테스트 데이터 8,884개, 검증 데이터 11,105개로, 범죄 미발생 지역(Safe)은 학습 데이터 18,653개, 테스트 데이터 4,663개, 검증 데이터 5,830개로 데이터셋을 구성하였다.




Fig. 3 Full-dataset



Fig. 4 Crime data




Fig. 5 Safe data

3.4 서브 데이터셋 구성

데이터 특성의 일관성을 파악하기 위해 전체 데이터셋을 같은 크기의 두 서브 데이터셋으로 나누어 모델 학습, 검증 및 테스트 과정을 진행하였다. 첫 번째 서브 데이터셋은 범죄 발생 지역 학습 데이터 17,767개, 검증 데이터 5,552개, 테스트 데이터 4,442개와 범죄 미발생 지역 학습 데이터 9,326개, 검증 데이터 2,915개, 테스트 데이터 2,332개로 구성하였다. 두 번째 서브 데이터셋은 범죄 지역 학습 데이터 17,767개, 검증 데이터 5,553개, 테스트 데이터 4,442개와 범죄 미발생 지역 학습 데이터 9,327개, 검증 데이터 2,915개, 테스트 데이터 2,331개로 구성하였다.

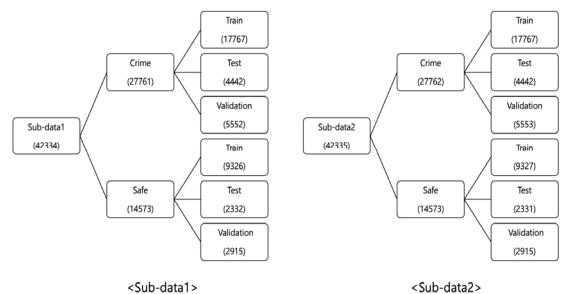


Fig. 6 Sub-dataset

3.5 모델 생성

3.5.1 초기 모델 생성

VGG16 모델은 keras 라이브러리를 사용하여 생성하였다.

3.5.2 전이학습 모델 생성

Imagenet을 학습한 VGG16 모델을 사용하여 전이 학습을 진행하였다. 학습 과정에서 기존의 VGG16 모델의 Convolution Layer는 학습되지 않도록 고정시켰다. 모델의 Fully Connected 부분은 Flatten-Dense (ReLU 함수 사용)-Dropout-Dense(Softmax 함수 사용)으로 재구성하였다. Baldi 등의 연구에 따르면, dropout을 0.5로 설정했을 때 정규화 효과가 가장 높은 것으로 나타났다.[15] 따라서, 과적합을 방지하기 위하여 두 개의 Dense층 사이에 0.5로 적용한 Dropout층을 삽입하였다. 또한, Max pooling층을 통해 과적합 문제를 방지하였다.

3.5.3 전이학습

학습 데이터와 검증 데이터 모두 이미지의 입력 크기를 224*224로 설정하였다. 학습 데이터는 무작위 추출이 가능하도록, 검증 데이터는 무작위 추출이 불가능하도록 설정하였다. 배치 사이즈(batch size)는 128, 에포크(epoch)는 25로 설정하였다. 손실함수는 categorical crossentropy로, 최적화 함수는 평균 제곱근 전파 (RMSProp)로, 마지막 층의 활성화 함수는 Softmax로 설정하였다.

특정 에포크에서 성능이 증가하지 않을 때, 과적합과 과소적합을 방지하기 위해서 학습을 중지시키는 Early Stopping 함수를 사용하였다. Early Stopping에 의해 학습이 중지되었을 때, 검증 성능이 가장 좋은 모델을 저장하기 위해 ModelCheckpoint 함수를 사용하였다. 이는 검증 오차를 모니터링하면서 이전 에포크에 비해 성능이 좋은 경우, 그때의 파라미터를 저장하는 기능을 하며, 트레이닝이 중지되었을 때 검증 성능이 가장 높았던 모델을 반환한다.

Table. 1 Model Feature

Model Feature	
Batch size	128
Epoch	25
Loss function	Categorical Crossentropy
Optimizer	RMSProp
Activation function	Softmax
Callback	Early Stopping, ModelCheckpoint

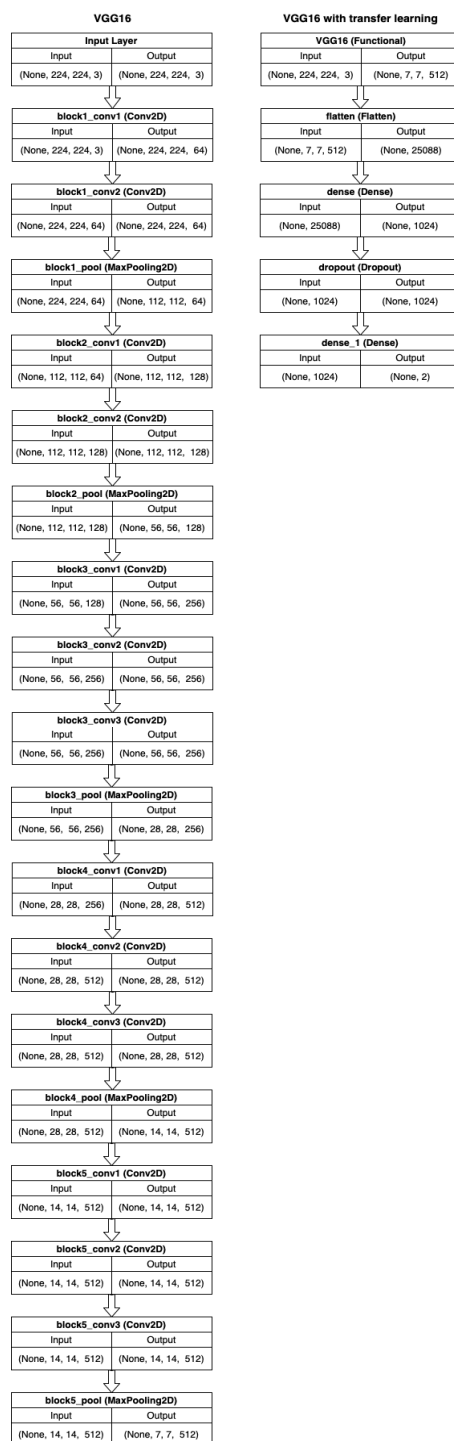


Fig. 7 Model structure

IV. 결론 및 제언

4.1 결론

서브 데이터셋 1의 학습 정확도는 0.7670, 학습 손실은 0.5521, 검증 정확도는 0.7328, 검증 손실은 2.3614이다. 테스트 정확도는 0.7185이다.

서브 데이터셋 2의 학습 정확도는 0.7590, 학습 손실은 0.5412, 검증 정확도는 0.7132, 검증 손실은 2.2701이다. 테스트 정확도는 0.7325이다.

Table. 2 Result

	Sub-dataset 1	Sub-dataset 2
Train Accuracy	0.7670	0.7590
Train Loss	0.5521	0.5412
Validation Accuracy	0.7327	0.7132
Validation Loss	2.3614	2.2701
Test Accuracy	0.7185	0.7325

서브 데이터셋에서 도출된 학습 정확도, 학습 손실, 검증 정확도, 검증 손실, 학습 정확도가 데이터셋 간 유사함을 확인할 수 있었다. 이는 가로경관이 범죄 발생에 유의미한 영향을 미친다는 것을 시사한다.

Imagenet 이미지 분류 시 VGG16 모델이 약 74.4%의 정확도 성능을 가지는 것과 비교하였을 때, 도출된 평균 72.55%의 정확도 성능 또한 유의미하다.

4.2 제언

4.2.1 연구의 의의

본 연구는 기존 연구가 설문조사 등으로 수집한 주관적 지표를 바탕으로 범죄와 가로경관 사이의 상관관계를 파악한 것과 달리, 객관적인 실제 범죄 발생 데이터를 사용하여 상관관계를 파악하였다. 이로써 개개인의 특성에 따라 달라질 수 있는 데이터의 일관성을 크게 높이고, 주관적 지표가 당면하는 신뢰도 하락 문제 또한 해결할 수 있었다.

아울러, 기존 연구가 잠재적 피해자의 입장에서 행해진 것과 달리, 범죄 주체 입장에서의 범죄 발생 요인을 파악하는 관점을 취하였다. 기존 연구의 경우, 도로경관과 범죄 발생의 상관관계 파악을 위한 위험성 데이터 수집 과정에서, 사진을 보고 위험 여부를 판단하는 실험 방식을 채택하였다. 이는 기존 연구가 범죄 발생

가능성을 가해자가 아닌 피해자가 판단하도록 함으로써 범죄 책임을 피해자에게 전가하는 양상을 보임을 내포한다. 그러나 범행은 가해자의 입장에서 자행됨을 고려되어야 하므로 피해자가 아닌 가해자 관점에서의 범행 가능성 판단이 필요하다.

본 연구는 이미지 기반 딥러닝 모델의 가로경관을 통한 우범지역 예상 가능성을 시사한다. 이는 딥러닝 모델의 활용이 우범 예상 지역의 순찰 강화, 낙후 지역 외관 재구축, 공공시설의 설치 등의 치안 강화 행위 등으로 이어져 범죄 예방에 긍정적인 영향을 미칠 수 있음을 의미한다. 뿐만 아니라, 치안에 직접적으로 관여하는 경찰청 산하 관공서뿐만 아니라 안전이 중요하게 고려되는 어린이, 청소년 관련 시설의 입지 선정에도 도움이 될 수 있음을 함축한다. 또한, 추후 가로경관과 범죄 발생 요인을 보다 정밀하게 파악하는 것이 도시 계획의 측면에서 유의미한 범죄 예방책을 도출하는 실질적인 해결책 중 하나임을 의미한다.

4.2.2 연구의 한계 및 후속 연구 제언

먼저, 데이터셋이 GSV에 의존했다는 점에서 데이터 전처리의 한계가 있다. 직접 촬영한 데이터가 아니기 때문에 날씨와 일조량 등의 기상환경과 촬영 시각에 따라 결과물의 화이트밸런스 등이 상이하다. API를 사용하는 과정에서 도로의 방향을 이미지상에서 동일하게 배열하지 못하였다는 점에서 데이터 간의 통일성이 떨어지는 문제점 또한 존재한다. 데이터셋 라벨링의 이진 분류 체계 역시 범죄 발생 횟수에 따른 위험도를 고려하지 않았으므로 정확도에 영향을 미쳤을 수 있다.

모델은 CNN 초기 모델에 속하는 VGG16을 사용하였는데, 시계열적 특성이 두드러지게 나타나는 범죄의 특성에도 불구하고 다른 모델의 적합성을 고려하지 않았으며, 선행 연구에서 범죄와의 연관성이 밝혀진 유동 인구와 같은 타 물리적 요소를 제어할 수 있는 방안을 모색하지 못하였다.

데이터 보안 및 수집의 한계로 대한민국이 아닌 시카고의 범죄 발생 데이터를 사용하였다. 법률과 주거 형태, 가치관 등 환경이 다른 시카고의 데이터를 국내 가로경관 및 범죄에 적용할 수 있는지에 대한 교차검증이 불가능하여 범용성을 보증할 수 없다는 점에서 한계를 보인다.

따라서 데이터셋 전처리 과정에서 화이트벨런스 조정 등을 통하여 기상환경과 촬영 시각으로 인한 데이터 차이를 최소화할 방안을 모색하여야 한다. 또한, 국내 데이터셋 구축으로 보다 국내 범죄 예측에 적합한 모델을 구현할 필요가 있다.

ACKNOWLEDGEMENTS

Following are results of a study on the "Convergence and Open Sharing System" Project, supported by the Ministry of Education and National Research Foundation of Korea and was supported by the National Research Foundation of Korea(NRF) grant funded by the Korea government(MSIT) (No.NRF-2022 R1F1A1074696).

REFERENCES

- [1] P. Topinard. "De la notion de race en anthropologie," *Revue d'Anthropologie*, vol. 2, pp. 589-660, 1879. DOI:10.2331/suisan.32.804.
- [2] W. H. Wilson. "The Glory, Destruction, and Meaning of the City Beautiful Movement," *The Johns Hopkins University Press*, pp 281-305, 1989.
- [3] J. Jacobs. "The Death and Life of Great American Cities," *Random House, New York*, 1961.
- [4] C. R. Jeffery, "Crime Prevention Through Environmental Design," *American Behavioral Scientist*, vol. 14, no. 4, pp. 598-598, 1971. DOI: 10.1177/000276427101400409.
- [5] O. Newman, "Defensible Space; Crime Prevention through Urban Design," *Macmillan Publishing*, 1972.
- [6] J. Roh and B. Park, "A Study of Crime Anxiety in the Region Using CPTED Index - Focusing on Alleyway Landscape Elements -", *Journal of Integrated Design Research*, vol. 16 no. 4, pp. 91-104, 2017. DOI:10.21195/jidr.2017.16.4.008.
- [7] M. Shin and E. M. Kim, "Analysis of Relation between Five Crime Types and Physical Environmental Factors," *Journal of the Korean Cartographic Association*, vol. 18, no. 3, pp. 131-140, 2018. DOI:10.16879/jkca.2018.18.3.131.
- [8] C. K. Kim, I. J. Kang, D. H. Park and S. S. Kim, "Analysis of the Five Major Crime Utilizing the CorrelationRegression Analysis with GIS," *Journal of Korean Society for Geospatial Information Science*, vol. 22, no.3, pp. 71-77, 2014. DOI: 10.7319/kogsis.2014.22.3.071.
- [9] G. I. Lee and H. Kang, "A Deep Learning-based Streetscapes Safety Score Prediction Model using Environmental Context from Big Data," *Journal of Korea Multimedia Society*, vol. 20, no. 8, pp. 1282-1290, 2017. DOI : 10.9717/kmms.2017.20.8.1282.
- [10] Hanyang University Industry - University Cooperation Foundation, 「Final Report on the Development of Neighborhood Landscape Assessment Deep Learning Model and Crowdsourcing Platform based on Visual-Cognitive Perception associated with Citizen Participation Program for Smart City」, 2021.
- [11] K. Park, D. Ki and S. Lee, "Analysis of Visual Characteristics of Urban Street Elements on Walking Satisfaction in Seoul, Korea," *Journal of the Urban Design Institute of Korea Urban Design*, vol. 22, no. 3, pp. 55-72, 2021. DOI:10.38195/judik.2021.06.22.3.55.
- [12] S. Kim, "Analysis of the Effects of Urban Environmental Characteristics on the Incidence Density by Crime Type: Using Urban Big Data and Spatial Durbin Model," *Journal of The Urban Design Institute of Korea*, vol.23, no.3, pp. 143-162, 2022. DOI:10.38195/judik.2022.06.23.3.143.
- [13] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," in *3rd International Conference on Learning Representations (ICLR 2015)*, San diego: CA, Computational and Biological Learning Society pp.1-14, 2015. DOI:10.48550/arXiv.1409.1556.
- [14] S. Heo, J. Kim and T. Moon, "Predicting Crime Risky Area Using Machine Learning," *Journal of the Korean Association of Geographic Information Studies*, vol. 32, no. 4, pp. 64-80, 2018. DOI:10.11108/kagis.2018.21.4.064.
- [15] P. Baldi, P. Sadowski, "Understanding Dropout," *Advances in Neural Information Processing system 26(NIPS 2013)*, Nevada : NV, vol. 2, pp.2814-2822, 2013.



김서영(Seoyeong Kim)

성균관대학교 인공지능융합전공

※관심분야 : 인공지능, 기계학습, 딥러닝, 컴퓨터비전



노하연(Hayeon Noh)

성균관대학교 인공지능융합전공

※관심분야 : 기계학습, 딥러닝, 컴퓨터비전



윤예원(Yewon Yoon)

성균관대학교 인공지능융합전공

※관심분야 : 인공지능, 뇌인지과학



이해민(Haemin Lee)

성균관대학교 인공지능융합전공

※관심분야 : 딥러닝, 컴퓨터비전



정진웅(Jinwoong Jung)

성균관대학교 인공지능융합전공

※관심분야 : 앱/웹 개발, 백엔드, 딥러닝-자연어처리



오하영(Hayoung Oh)

성균관대학교 부교수 (2019~)

아주대학교 조교수 (2016~2019)

숭실대학교 조교수 (2013~2016)

서울대학교 컴퓨터공학부 박사 (2013)